

Universidade do Minho

Sistema de Apoio à Decisão para a Walmart

Tecnologias de Inteligência Artificial na Previsão e Otimização em
Sistemas Empresariais

Grupo 6- TP2

TRABALHO REALIZADO POR:

João Pedro de Carvalho Mendes PG53938

Marco Meira Pires PG54032

Miguel Malheiro Ferreira PG54102

Ricardo Barbosa Gonçalves Pereira PG54178

Índice

Introdução.....	2
Execução do Projeto:	3
Previsão	8
Previsão Univariada.....	8
Resultados das previsões.....	9
Previsão Multivariada	13
Objetivos de otimização.....	16
Modelos.....	16
Regras de negócio	17
Desenvolvimento do objetivo de otimização.....	17
Resultados de Otimização.....	19
Demonstração do Sistema Desenvolvido	22
Conclusão.....	23
Referências	24

Introdução

No âmbito da unidade curricular de Técnicas de Inteligência Artificial na Previsão e Otimização em Sistemas Empresariais, desenvolvemos um sistema de apoio à decisão para o Walmart. O principal objetivo deste sistema consiste em otimizar a gestão de inventário e de recursos nas lojas da Walmart. Para tal, recorremos a técnicas avançadas de inteligência artificial para prever e maximizar as vendas semanais em quatro departamentos distintos.

O principal objetivo da empresa é maximizar o lucro total. Numa segunda etapa, visa não apenas maximizar o lucro, mas também minimizar o esforço manual. Para atingir esse objetivo, teremos de implementar um sistema de previsão que use o histórico de vendas de cada departamento para prever um mês de vendas e um sistema de otimização que proponha um plano para dar resposta à previsão de vendas.

Finalmente, este relatório apresentará o trabalho desenvolvido pelo grupo nas fases de previsão e otimização. Numa primeira fase, expondo o melhor modelo preditivo através das métricas utilizadas e, posteriormente, com base nisso, a etapa da otimização onde o objetivo será fornecer à empresa informações sobre o número de funcionários que é necessário contratar e o número de encomendas que é necessário fazer a cada mês, com o objetivo de maximizar o lucro e também, em outra componente, minimizar o esforço manual.

Execução do Projeto:

O presente projeto foi desenvolvido pelos alunos João Mendes, Marco Pires, Ricardo Pereira e Miguel Ferreira no decorrer da unidade curricular de Técnicas de Inteligência Artificial na Previsão e Otimização em Sistemas Empresariais, sob a orientação do professor Paulo Cortez.

O projeto foi dividido em duas fases distintas. Na primeira fase, focamos na previsão e estudamos métodos univariados e multivariados, tendo sido testados à posteriori. Cada membro do grupo ficou responsável por estudar e implementar esses métodos, utilizando a growing window para todos para uma melhor experiência.

Na segunda fase, efetuamos os processos de otimização, desenvolvendo as funções necessárias para maximizar o lucro ou maximizar o lucro e minimizar o esforço manual e implementamos tanto a componente de previsão como a componente de otimização numa interface gráfica utilizando o shiny.

Todas estas componente foram desenvolvidas em conjunto pela equipa. Considerando o esforço e tempo dedicados a este projeto, juntamente com a melhoria e aprendizado contínuos do grupo ao longo das semanas, acreditamos que a nota de 17 valores seja justa para este trabalho. O nosso objetivo foi sempre trabalhar semana após semana e entregar um projeto completo e bem estruturado, obtendo sempre melhorias de forma a aprender ao longo do processo. Posto isto, avaliamo-nos individualmente com João Mendes – 18 valores, Marco Pires – 17 valores, Ricardo Pereira – 17 valores e Miguel Ferreira – 17 valores.

João Mendes

Quanto à primeira componente do presente projeto, relativa à previsão, fiquei encarregue pelo desenvolvimento dos modelos univariados Linear Regression e Random Forest, assim como das suas respectivas execuções/previsões e documentação. Além disso, estudei e implementei modelos com a técnica de "growing window". Para os modelos multivariados, fiquei encarregue pelo desenvolvimento do modelo ARIMAX, implementando este modelo com a técnica de Growing Window. Também implementei a função snaive, para verificar a qualidade em % das previsões obtidas pelo nosso melhor modelo.

A nível da segunda componente, relativa à otimização, para além de implementar a função eval, como todos os cálculos necessários para obter o lucro e o esforço, fiquei encarregado de implementar os modelos de otimização Monte Carlo, Tabu Search e Differential Optimization, desenvolvendo a Growing Window para otimização com valores previstos. Também trabalhei na implementação do multiobjetivo (O2), criando a função eval2 para devolver o lucro negativo e da curva de Pareto, e também realizei a implementação da interface gráfica utilizando o shiny, implementando tanto a componente de previsão como a componente de otimização.

Para além disso, realizei todas as tarefas propostas e compareci a todas as reuniões realizadas ao longo do projeto, contribuindo de forma ativa e colaborativa. As reuniões semanais foram cruciais para a discussão do progresso e a resolução de problemas, e eu desempenhei um papel significativo na organização e condução dessas reuniões, garantindo o alinhamento e a eficiência do grupo.

Marco Pires

Quanto à primeira componente do presente projeto, relativa à previsão, fiquei encarregado pelo desenvolvimento dos modelos LM e ARIMA, assim como das suas respectivas execuções/previsões e documentação. Além disso, estudei e implementei modelos com a técnica de "growing window". Para os modelos multivariados, fiquei encarregue pelo desenvolvimento do modelo ARIMAX, implementando este modelo com a técnica de Growing Window.

A nível da segunda componente, relativa à otimização, fiquei encarregado de implementar o modelo Sann, desenvolvendo a Growing Window para otimização com valores previstos. Também participei na implementação do multi-objetivo (O2) e da curva de Pareto, além de contribuir para a interface das previsões usando Shiny.

Para além disso, realizei todas as tarefas propostas e compareci a todas as reuniões realizadas ao longo do projeto, contribuindo de forma ativa e colaborativa. As reuniões semanais foram cruciais para a discussão do progresso e a resolução de problemas, e eu desempenhei um papel significativo na organização e condução dessas reuniões, garantindo o alinhamento e a eficiência do grupo.

Ricardo Pereira

Quanto à primeira componente do presente projeto, relativa à previsão, fiquei encarregado pelo desenvolvimento dos modelos Exponential Smoothing (ETS) e HoltWinters, assim como das suas respectivas execuções/previsões e documentação. Além disso, estudei e implementei modelos com a técnica de "growing window". Para os modelos multivariados, fiquei encarregue pelo desenvolvimento do modelo VAR, implementando este modelo com a técnica de Growing Window.

A nível da segunda componente, relativa à otimização, fiquei encarregado de implementar o modelo Hill Climbing e RGBA, desenvolvendo a Growing Window para otimização com valores previstos. Também implementei os calculos dos limites superiores e inferiores, para a solução nos devolver valores previstos pelos limites. Também participei na implementação do multi-objetivo (O2) e da curva de Pareto. Por fim, ajudei a implementari a interface gráfica usando o Shiny.

Para além disso, realizei todas as tarefas propostas e compareci a todas as reuniões realizadas ao longo do projeto, contribuindo de forma ativa e colaborativa. As reuniões semanais foram cruciais para a discussão do progresso e a resolução de problemas, e eu desempenhei um papel significativo na organização e condução dessas reuniões, garantindo o alinhamento e a eficiência do grupo.

Miguel Ferreira

Quanto à primeira componente do presente projeto, relativa à previsão, fiquei encarregado pelo desenvolvimento dos modelos Random Forest e MLPE, assim como das suas respectivas execuções/previsões e documentação. Além disso, estudei e implementei modelos com a técnica de "growing window". Para os modelos multivariados, fiquei encarregue pelo desenvolvimento do modelo VAR, implementando este modelo com a técnica de Growing Window.

A nível da segunda componente, relativa à otimização, fiquei encarregado de implementar o modelo Monte Carlo e Tabu Search, desenvolvendo a Growing Window para otimização com valores previstos. Também participei na implementação do multiobjetivo (O2) e da curva de Pareto.

Para além disso, realizei todas as tarefas propostas e compareci a todas as reuniões realizadas ao longo do projeto, contribuindo de forma ativa e colaborativa. As reuniões semanais foram cruciais para a discussão do progresso e a resolução de problemas, e eu desempenhei um papel significativo na organização e condução dessas reuniões, garantindo o alinhamento e a eficiência do grupo.

Previsão

Na primeira etapa do projeto, começámos por realizar estudos preliminares para determinar quais os modelos de previsão a utilizar, sempre com o auxílio do material fornecido pelo docente. Após esta análise, demos início à execução das previsões, recorrendo a vários modelos univariados.

Para a realização de uma análise mais robusta dos modelos de previsão, aplicamos o método Growing Window aos modelos de previsão desenvolvidos, tal como sugerido pelo docente. Posteriormente, foi aplicada a metodologia Growing Window aos vários modelos já realizados. Para isso, foram definidos os parâmetros de acordo com o enunciado do projeto e o objetivo a retirar do mesmo.

Para uma análise mais aprofundada dos modelos de previsão, adotámos o método Growing Window, tal como indicado pelo docente. Os parâmetros foram definidos de acordo com o enunciado do projeto e os objetivos estabelecidos. Deste modo, considerámos L como o número de linhas do conjunto de dados, exceto os dados do último mês que corresponde a 4 linhas. No caso do conjunto de dados "walmart", este valor é 139. O parâmetro S foi definido como K , onde $K = 4$, representando as quatro semanas do mês, e realizámos 10 iterações para cada modelo. Este ajuste revelou-se crucial para satisfazer as exigências do projeto, que tinha como objetivo prever as vendas semanais para os últimos meses.

Previsão Univariada

Com base nos pacotes RMINER e Forecast, foram implementados um total de 6 métodos univariados para análise de dados:

Pacote Rminer:

Random Forest: Método que utiliza múltiplas árvores de decisão para realizar previsões, melhorando a precisão e controlando o sobreajuste através da média das previsões de várias árvores.

LM: Modelo baseado em regressão linear que estabelece uma relação linear entre variáveis dependentes e independentes para fazer previsões simples e diretas.

MLPE: Variação do MLP que inclui um tratamento específico de erro persistente, aprimorando a capacidade do modelo de lidar com previsões em séries temporais onde a precisão é crítica.

Pacote Forecast:

Arima: Modelo autorregressivo integrado de média móvel, utilizado para prever séries temporais, ajustando-se a dados que mostram padrões não estacionários através da diferenciação.

Holt-Winters: Método de suavização exponencial que ajusta a série temporal levando em conta tanto a tendência quanto a sazonalidade, ideal para os dados com padrões cíclicos claros.

ETS: Modelo de suavização exponencial que utiliza um espaço de estados para modelar e prever séries temporais, considerando componentes de erro, tendência e sazonalidade de forma individual ou combinada, adaptando-se dinamicamente a mudanças nos padrões dos dados.


Resultados das previsões

Na primeira fase do nosso projeto, concentrámo-nos no desenvolvimento e afinação de modelos de previsão para estimar as vendas semanais de cada departamento na Walmart para a semana seguinte. Utilizamos uma variedade de modelos de previsão, que incluem os pacotes rminer e forecast, de forma a captar as diversas dinâmicas e padrões dos dados de vendas.


Numa primeira fase treinamos os modelos com todos os dados exceto os do último mês (últimas 4 semanas), e fizemos previsões dos mesmos. De seguida avaliamos e reajustamos se os modelos faziam sentido e obtivemos gráficos de valores previstos vs valores desejados.

Numa fase seguinte, fizemos um estudo mais robusto de comparação de métodos de previsão. Para isso, desenvolvemos um método de validação Growing Window para os últimos 10 meses (10 iterações), ou seja, prevíamos 4 semanas em cada iteração.


Real vs Todos Modelos - Departamento: WSdep1 Iteração:




Real vs Todos Modelos - Departamento: WSdep2 Iteração:



Real vs Todos Modelos - Departamento: WSdep3 Iteração:



Real vs Todos Modelos - Departamento: WSdep4 Iteração:



Para avaliar a precisão e eficácia dos modelos implementados, recorremos a um conjunto de métricas detalhadas, que foram apresentadas em tabelas. As métricas utilizadas para medir o desempenho dos modelos incluíram o Erro Médio Absoluto (MAE), o Erro Médio Absoluto Normalizado (NMAE), a Raiz do Erro Quadrático Médio (RMSE), o Erro Quadrático Médio Relativo (RRSE) e o coeficiente de determinação (R^2). Estas métricas forneceram-nos uma visão abrangente da precisão das previsões, permitindo identificar os modelos que melhor se ajustaram ao comportamento dos dados de vendas.

Fizemos uma mediana das métricas de cada departamento, e os resultados obtidos foram os seguintes:

DEPARTAMENTO 1

Modelo	MAE	NMAE	RMSE	RRSE	R2
Arima	7738.279	4.457046	9159.346	138.7079	0.3295641
Random Forest	2839.7	1.635593	3993.115	294.1166	0.4152001
ETS	13133.52	7.564563	16605.63	230.679	0.1355663
LM	4031.719	2.322164	4220.566	498.4157	0.9240369
MLPE	2503.289	1.441829	3160.387	220.8145	0.2414523
HoltWinters	10719.54	6.174177	13160.03	191.333	0.06276797

DEPARTAMENTO 2

Modelo	MAE	NMAE	RMSE	RRSE	R2
Arima	8608.984	9.712959	9896.4	75.06191	0.6739724
Random Forest	6087.028	6.867599	7750.428	65.51296	0.7008814
ETS	7591.761	8.565292	8797.932	65.38515	0.6499077
LM	4244.69	4.789009	5185.968	45.96315	0.9129106
MLPE	5490.327	6.19438	6627.098	57.19643	0.7740817
HoltWinters	15589.59	17.58872	17245.95	125.8132	0.8284964

DEPARTAMENTO 3

Modelo	MAE	NMAE	RMSE	RRSE	R2
Arima	2955.217	7.376425	4166.923	141.2012	0.09179309
Random Forest	2973.652	7.422441	3450.548	88.93475	0.3287225
ETS	4333.525	10.81678	5879.146	212.6135	0.7535202
LM	2136.036	5.331693	2572.342	70.74344	0.9768836
MLPE	2418.506	6.036757	2846.405	80.40271	0.5961136
HoltWinters	3710.92	9.26271	4848.832	163.8835	0.2075824

DEPARTAMENTO 4


Modelo	MAE	NMAE	RMSE	RRSE	R2
Arima	4786.453	8.633728	5288.918	76.54669	0.8157003
Random Forest	5839.916	10.53395	6567.558	83.55506	0.6593327
ETS	7442.392	13.42447	8761.303	139.9152	0.4791869
LM	3714.183	6.699585	4419.312	57.64906	0.8441626
MLPE	5154.659	9.297893	5610.665	73.81608	0.5111488
HoltWinters	7577.134	13.66752	9430.897	135.0346	0.5655491

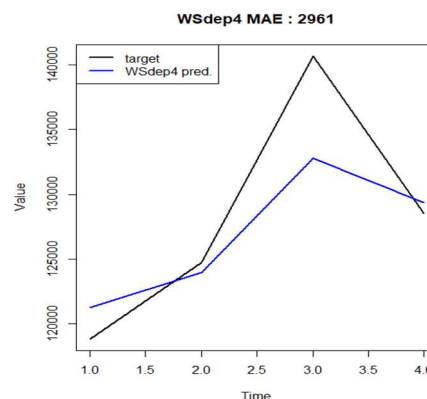
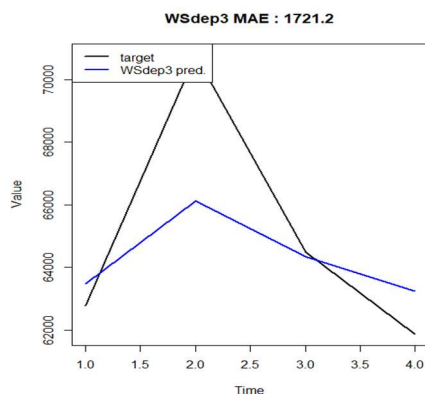
--	--	--	--	--	--

A análise das métricas indicou que o nosso modelo LM se destacou consistentemente em vários departamentos, apresentando os melhores resultados tanto em termos de menor erro quanto de maior precisão preditiva. Este modelo, que combina técnicas avançadas de machine learning e aprendizagem profunda, demonstrou ser extremamente eficaz ao lidar com a complexidade e variabilidade dos dados de vendas da Walmart.

O sucesso do LM nas previsões para a semana seguinte nos departamentos específicos deveu-se à sua capacidade de captar as dinâmicas importantes dos dados, consolidando-o como o modelo preferencial para avançar nas fases subsequentes do nosso projeto. Assim, escolhemos este modelo como a ferramenta analítica principal para orientar decisões estratégicas e otimizações futuras, com o objetivo de maximizar a precisão das previsões.

Adicionalmente, visualizámos o desempenho do modelo LM através de gráficos que representam as previsões de vendas semanais para os quatro departamentos da Walmart. Cada gráfico mostra a comparação entre os valores reais de vendas ('target') e as previsões geradas pelo modelo ('WSdep pred.') ao longo de quatro semanas.





Previsão Multivariada



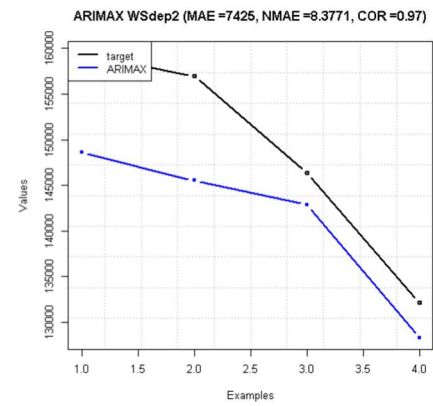

Na fase de previsão multivariada, no âmbito da presente investigação, foram adotados dois modelos distintos: ARIMAX e VAR. Após uma análise minuciosa dos resultados obtidos, tornou-se evidente que o modelo ARIMAX se destacou, oferecendo resultados significativamente superiores em comparação com o modelo VAR.

O modelo ARIMAX, ao integrar as vantagens dos modelos ARIMA com a inclusão de variáveis exógenas, demonstrou uma capacidade excepcional na captura das intrincadas relações entre as variáveis do conjunto de dados. Ao incorporar informações externas relevantes, conseguiu gerar previsões mais precisas e robustas.

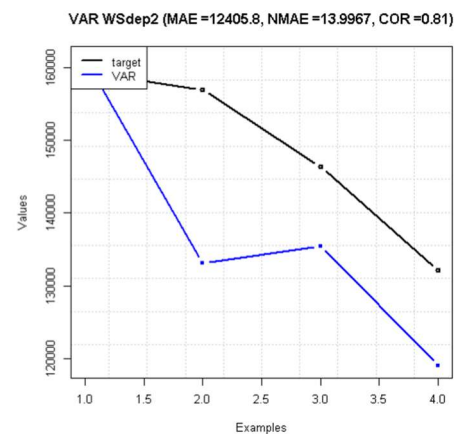
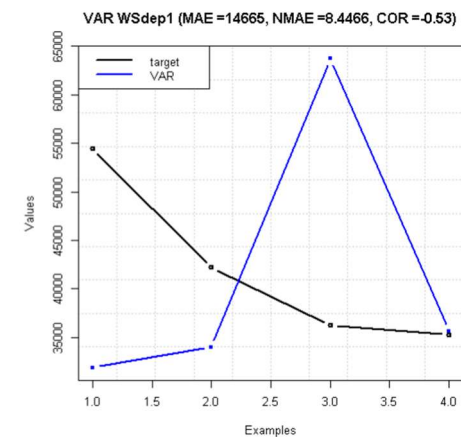
Por outro lado, apesar do reconhecimento do modelo VAR pela sua capacidade de modelar relações de causalidade entre múltiplas séries temporais, não conseguiu rivalizar com o desempenho exibido pelo modelo ARIMAX no contexto específico desta investigação.


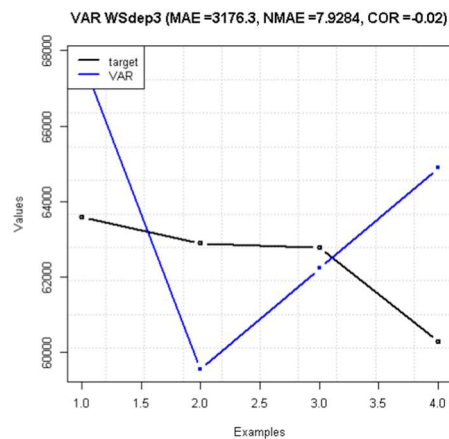
Assim, com base na análise comparativa dos resultados obtidos, é possível concluir que o modelo ARIMAX se apresenta como a escolha mais adequada para a tarefa de previsão multivariada neste cenário específico, contribuindo de forma significativa para a compreensão e previsão das dinâmicas das variáveis em estudo.

ARIMAX:

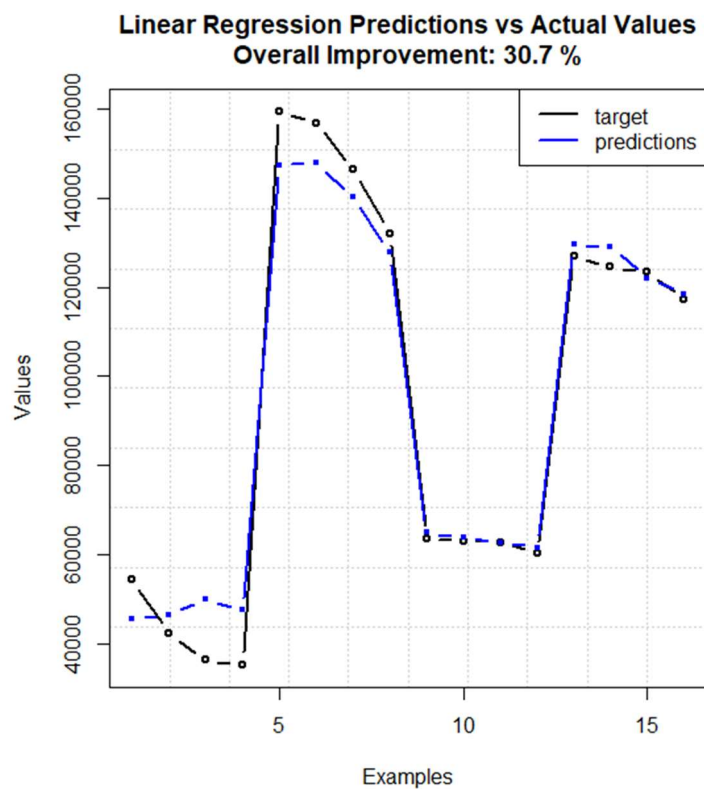


VAR:





De maneira a avaliar a qualidade das previsões obtidas, fizemos uma comparação entre o NMAE do LM e o NMAE do Seasonal Naive para todos os departamentos, de forma a entender quão melhor são as previsões em %, e interpretamos os resultados obtidos num gráfico:



Este valor de 30.7% representa a melhoria percentual geral no erro de previsão quando usando o modelo de regressão linear em comparação com o método *snaive*. Significa que o modelo de regressão linear foi capaz de reduzir o erro nas previsões em 30.7% em média, comparado ao erro do modelo *snaive*, em todo o conjunto de dados analisado. Esta melhoria de 30.7% sugere que a regressão linear conseguiu capturar padrões complexos nos dados históricos de vendas que o modelo *snaive*, mais simples e baseado na repetição de padrões sazonais anteriores, não pôde detectar.

Objetivos de otimização

Modelos

Os modelos que trabalhamos na fase de otimização foram os seguintes:

Monte Carlo: Utilizando a função *eval*, os vetores *lower* e *upper*, o número de iterações e o tipo de otimização, aplicamos o método Monte Carlo. Neste método, é essencial realizar um grande número de iterações para obter soluções vantajosas. Assim sendo, definimos uma variável *N* para lidar com a aleatoriedade inerente ao método. A abordagem consiste em gerar um grande conjunto de amostras aleatórias para estimar os comportamentos de um sistema complexo.

Hill Climbing: Para otimizar uma função objetivo, implementamos o método Hill Climbing, que começa com uma solução inicial e faz melhorias incrementais. A cada iteração, o algoritmo examina as soluções vizinhas e move-se para a melhor solução adjacente. Este processo continua até que não haja mais melhorias possíveis. O Hill Climbing é eficiente em encontrar ótimos locais e é adequado para problemas onde uma busca gradual pode levar a boas soluções.

Simulated Annealing: Utilizamos o algoritmo de Simulated Annealing para encontrar soluções quase ótimas em problemas com múltiplos máximos e mínimos locais. Inspirado no processo de recozimento de metais, o método permite a aceitação de soluções subótimas temporariamente para evitar ficar preso em ótimos locais. A probabilidade de aceitar essas soluções diminui gradualmente, permitindo uma exploração ampla no início e uma busca refinada no final.

Tabu Search: Para otimizar problemas complexos, usamos o método Tabu Search, que aprimora continuamente uma solução inicial através da exploração de soluções vizinhas. Para evitar ciclos e revisitar soluções anteriores, o algoritmo utiliza uma lista *tabu* que armazena movimentos recentes, promovendo a exploração de novas áreas do espaço de busca. Este método é eficaz em escapar de ótimos locais e encontrar a solução globalmente ótima.

RGBA: Para resolver problemas em espaços de busca discreta e combinatorial, utilizou-se este método de otimização. Ao longo do tempo, esse algoritmo evolui por meio de processos de seleção, recombinação e mutação, com o objetivo de encontrar as melhores soluções disponíveis.

DEO (Differential Evolution Optimization): Para resolver problemas globais e evoluir várias soluções ao longo do tempo, aplicamos o método Differential Evolution Optimization (DEO). Esse algoritmo de otimização é utilizado devido à sua capacidade de realizar operações de mutação, recombinação e seleção na busca por uma solução ótima. Com o DEO, mantemos e evoluímos múltiplas soluções ao longo do processo de otimização.

Regras de negócio

Funcionários:

Existem três tipos de funcionários: júnior, normal e sénior, com custos mensais de 6000 \$, 8000 \$ e 9750 \$, respetivamente. A capacidade de cada tipo de funcionário é de 4000, 7000 e 9500 produtos por semana, respetivamente (o quanto conseguem auxiliar).

Encomendas de Produtos:

Cada departamento tem um custo específico de encomenda por produto: 6 \$, 8 \$, 9 \$ e 11 \$ para os Departamentos 1, 2, 3 e 4, respetivamente.

Custos de Armazenamento:

Cada produto não vendido armazenado (stock) tem um custo de armazenamento por semana de 3 \$, 5 \$, 6 \$ e 8 \$ para os Departamentos 1, 2, 3 e 4, respetivamente.

Vendas e Lucros:

Os preços de venda por produto são de 8 \$, 10 \$, 12 \$ e 16 \$ para os Departamentos 1, 2, 3 e 4, respetivamente. A venda é restrita apenas aos produtos que podem ser suportados pelos funcionários disponíveis e pelo stock encomendado.

Desenvolvimento do objetivo de otimização

Para otimizar a gestão dos departamentos da Walmart, elaborámos um processo metódico que inicia com a definição de uma função de avaliação denominada `eval(s)`. Esta função é vital para o cálculo do lucro e do esforço, pois a mesma contém todos os cálculos necessários para retornar estes dois valores.

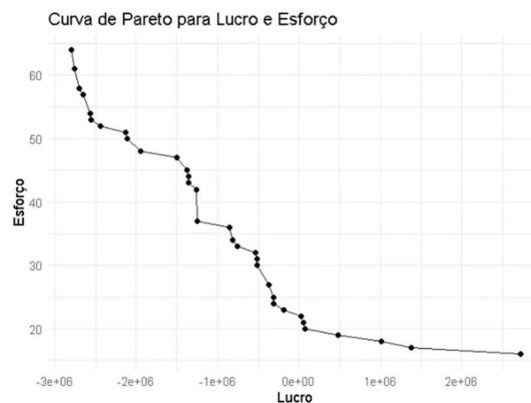
O problema de otimização é representado por um vetor s que contém 28 elementos, descrevendo o número de funcionários contratados e as quantidades de produtos encomendados por departamento ao longo de um mês. Este vetor divide-se em duas partes principais: os primeiros 12 elementos correspondem à quantidade de funcionários de três categorias—júnior, normal e sénior—para cada departamento. Os 16 elementos restantes destinam-se às encomendas de produtos para cada semana e departamento.

Estabelecemos limites inferiores e superiores para as variáveis no vetor s , com os limites inferiores fixados em 0 até 28, enquanto os limites superiores foram ajustados com base na capacidade máxima de cada departamento, considerando as previsões de vendas e a capacidade dos funcionários.

Para enfrentar de forma eficaz as complexidades deste problema, adotamos métodos de otimização, incluindo Monte Carlo, Hill Climbing, Tabu Search, Differential Evolution, RGBA e Sann. Sendo que apenas conseguimos implementar os cinco primeiros modelos na interface. Estas técnicas permitem uma exploração aprofundada das soluções ótimas tanto locais quanto globais, facilitando a identificação da configuração que maximiza o lucro ao mesmo tempo que minimiza os custos e o esforço operacional.

Implementamos também uma estratégia de otimização multi-objetivo por meio da função `eval2`, que devolve um vetor com o lucro negativo e o número total de esforço. Aqui, definimos um peso para o lucro e para o esforço e devolvemos o valor do cálculo - $w_1 \times \text{lucro} + w_2 \times \text{esforço} \times K$ na função `eval2`. O objetivo é maximizar o lucro e minimizar o esforço.

Usando o método multi-objetivo NSGA-II fizemos uma única execução de forma simultânea de forma a otimizar ambos os objetivos. Na imagem a seguir podemos observar a curva de Pareto gerada, com os dados previstos pelo nosso melhor modelo de previsão (LM):



Resultados de Otimização

Por último, fizemos uma execução de todos os métodos de otimização implementados para 8 meses. Esses meses foram previstos com a Growing Window (no caso 8 iterações, para nos dar a previsão dos últimos 8 meses) do melhor modelo de previsão obtido nos modelos de previsão, o LM.

E, novamente, utilizamos uma Growing Window de otimização que obrigatoriamente tem o mesmo número de iterações que a Growing Window da previsão, para percorrer os modelos de otimização por todos os meses.

O1:

Para a primeira componente de otimização, onde apenas se maximiza o resultado, os resultados da otimização para os oitos meses foram estes:

Meses	Montecarlo		Hill		Differential Evolution	
	Lucro	Esforço	Lucro	Esforço	Lucro	Esforço
Primeiro Mês	1068577.38	69	1482706.36	42	2091466.60	83
Segundo Mês	601181.15	62	1467103.71	41	865752.53	74
Terceiro Mês	656020.83	74	1072971.88	28	1169784.77	71
Quarto mês	472610.36	59	1661211.52	61	1355156.51	67
Quinto mês	610087.22	66	1149772.45	45	1720748.18	71
Sexto mês	733802.22	56	1864213.22	51	1744829.31	70
Sétimo mês	1038106.55	78	1475769.41	41	1288428.32	62
Oitavo Mês	675593.27	68	971369.63	49	1657200.93	75

Meses	Tabu Search		RGBA	
	Lucro	Esforço	Lucro	Esforço
Primeiro Mês	3260995.79	72	1937668.53	70
Segundo Mês	3292855.00	70	2204752.04	73
Terceiro Mês	3314500.00	67	1882191.10	64
Quarto mês	3474489.61	72	1859231.10	67
Quinto mês	3319144.00	68	2180988.50	68
Sexto mês	3359683.00	68	2067007.46	71

Sétimo mês	3032736.14	66	2043722.85	67
Oitavo Mês	3286652.53	73	2562144.29	70

Mediana Lucros Montecarlo: 541 348,79

Mediana Lucros Hill: 1471436,56

Mediana Lucros Differential Evolution: 1506178.72

Mediana Lucros Tabu Search: 3303677.50

Mediana Lucros RGBA: 2055365.15

Mediana Esforço Montecarlo: 67

Mediana Esforço Hill: 43,5

Mediana Esforço Differential Evolution: 71

Mediana Esforço Tabu Search: 69

Mediana Esforço RGBA: 70

Através destes resultados, podemos verificar que o modelo Tabu Search é o melhor modelo para a componente O1, pois a sua mediana dos 8 lucros é a maior.

O2:

Para a segunda componente de otimização, onde se maximiza o resultado e minimiza o esforço, criamos uma nova eval onde criamos uma função combinatória objetiva, onde atribuímos peso tanto ao lucro (w_1) como ao esforço (w_2). Os resultados da otimização para os oitos meses foram estes:

Meses	Montecarlo		Hill		Differential Evolution	
	Lucro	Esforço	Lucro	Esforço	Lucro	Esforço
Primeiro Mês	6865591.43	43	1260863.30	52	2003956.11	39
Segundo Mês	9572596.75	33	487921.53	39	3081034.12	35
Terceiro Mês	5390659.27	39	938127.98	52	4650219.20	32
Quarto mês	752731.15	54	1765810.14	47	3554214.26	35
Quinto mês	7610641.00	36	646725.26	36	2167823.24	37

Sexto mês	5481370.98	43	1201687.69	40	1479673.29	42
Sétimo mês	2151589.89	47	1856366.20	47	4605386.10	33
Oitavo Mês	4453771.11	49	1139227.00	33	3776565.67	38

Meses	Tabu Search		RGBA	
	Lucro	Esforço	Lucro	Esforço
Primeiro Mês	1260444.33	25	103830.65	44
Segundo Mês	483921.53	20	1025187.30	46
Terceiro Mês	1853366.20	36	231093.10	45
Quarto mês	1665310.14	33	701314.68	40
Quinto mês	938327.98	23	1419612.90	37
Sexto mês	2153589.89	40	742945.98	38
Sétimo mês	1469773.29	32	826560.48	41
Oitavo Mês	50002.40	16	1245632.00	41

Mediana Lucros Montecarlo: 5436015.125

Mediana Lucros Hill: 1170457.345

Mediana Lucros Differential Evolution: 3317624.19

Mediana Lucros Tabu Search: 1365108.81

Mediana Lucros RGBA: 784753.23

Mediana Esforço Montecarlo: 43

Mediana Esforço Hill: 47

Mediana Esforço Differential Evolution: 36

Mediana Esforço Tabu Search: 28.5

Mediana Esforço RGBA: 41

Como podemos verificar, em relação à tabela de cima os esforços foram minimizados em todos os métodos de otimização.

Demonstração do Sistema Desenvolvido

https://www.youtube.com/watch?v=okbD_AI46MY&ab_channel=Jo%C3%A3oMendes

Conclusão

Com base nos resultados obtidos ao longo da execução do projeto, podemos concluir que este empreendimento representou um passo significativo em direção à eficiência operacional e à maximização dos lucros para a empresa.

Na fase de previsão, utilizamos uma variedade de modelos univariados e multivariados, para prever o volume de vendas semanais em diferentes departamentos da Walmart. Através da análise das métricas de desempenho, como MAE, RMSE e R^2 , identificámos o modelo Linear Regression como o mais robusto e preciso para a nossa tarefa, destacando-se pela sua eficácia em produzir melhores previsões. Além disso, explorámos a previsão multivariada utilizando o modelo ARIMAX, que integra variáveis exógenas para melhorar a precisão das previsões. Concluimos assim que o ARIMAX superou o modelo VAR, oferecendo resultados mais consistentes e precisos na previsão das vendas nos diferentes departamentos da Walmart.

Na segunda fase do projeto, focámo-nos na otimização da gestão de recursos, utilizando métodos como Monte Carlo, Hill Climbing, Tabu Search e Differential Evolution e RGBA. Estes métodos permitiram-nos encontrar soluções ótimas que maximizam os lucros para o primeiro objetivo da otimização e maximiza o lucro e minimiza o esforço manual para o segundo objetivo otimização. Os resultados da otimização demonstraram melhorias significativas nos lucros ao longo dos meses, com destaque para o método Tabu Search, que obteve consistentemente os melhores resultados em termos de lucro mediano.

Este projeto proporcionou uma oportunidade única para aplicar e aprofundar os conhecimentos dados em aula. Os resultados obtidos não só demonstraram a eficácia das abordagens adotadas, mas também forneceram bons insights que podem orientar as decisões estratégicas futuras da Walmart. Este sistema de apoio à decisão representa um excelente recurso para a empresa, capacitando-a a tomar decisões informadas e eficazes que impulsionam o seu desempenho e competitividade no mercado.

Referências

Material disponibilizado pelo docente na blackboard.

ChatGPT

<http://www3.dsi.uminho.pt/pcortez/rminer.html>

<http://repositorium.sdum.uminho.pt/handle/1822/36210>

<https://www.rdocumentation.org/packages/rminer/versions/1.0/topics/mmetric>

<https://programando-em-shiny.curso-r.com/referencias.html>

<https://cran.r-project.org/web/packages/forecast/index.html>